

Fabio Barboza de Oliveira

Engenheiro de Software Sênior | Engenheiro de IA | Arquitetura e Sistemas Distribuídos

São José, SC, Brasil • (48) 98409-7266 • barboza.oliveira@gmail.com • linkedin.com/in/fabio-oliveira-20a977a1 • github.com/fabio-barboza

RESUMO

Engenheiro de software com mais de 20 anos em arquitetura e desenvolvimento de sistemas distribuídos de alta escala, atuando em microsserviços, arquitetura orientada a eventos e plataformas corporativas em produção nos setores de logística, financeiro e Open Banking. Experiência em todo o ciclo de vida do produto, da concepção da arquitetura à operação, com foco em alta disponibilidade, automação e segurança. Nos últimos anos incorporou IA aplicada à engenharia, construindo agentes, RAG e servidores MCP em Java e Python, além de um framework open source de desenvolvimento orientado a especificação. MBA em Arquitetura de Software e pós-graduação em Inteligência Artificial e Aprendizado de Máquina.

COMPETÊNCIAS TÉCNICAS

Backend e Arquitetura: Java (Spring Boot, Quarkus, GraalVM), Go, Node.js/NestJS, Python. Microsserviços e arquitetura orientada a eventos, APIs REST e gRPC, Kafka, RabbitMQ, SQS, Docker, Kubernetes, AWS, PostgreSQL.

IA e LLMs: Python, FastAPI, LangChain, LangGraph, Spring AI, MCP (cliente e servidor, FastMCP), tool calling, RAG agêntico, bases vetoriais (pgvector, Chroma), guardrails, evals de agentes, observabilidade com Langfuse, prompt engineering, structured output, inferência e quantização de modelos locais (GGUF), pipelines de voz STT/TTS.

Segurança: Autenticação, autorização e controle de acesso (OAuth2/OIDC, SSO, Spring Security) em sistemas de larga escala.

Automação com IA no fluxo de engenharia: Claude Code, OpenCode, Cursor e GitHub Copilot, com Spec-Driven Development.

EXPERIÊNCIA PROFISSIONAL

Engenheiro de Software • Grupo Boticário mar/2023 – ago/2026

- Desenvolvimento de microsserviços para logística, atuando em todo o ciclo de vida do produto, com foco em alta disponibilidade e automação em produção de alta escala.
- IA aplicada como diferencial de produtividade: ferramentas de IA integradas ao fluxo de engenharia para refinamento técnico, geração e revisão de código e identificação de edge cases, resultando em ciclos de entrega mais curtos e menos retrabalho.

Tecnologias: Java (Spring Boot, Quarkus, GraalVM), Node.js/NestJS, Go, gRPC, Kafka, RabbitMQ, SQS, PostgreSQL, React, Docker, AWS, ArgoCD, Elasticsearch, New Relic.

Analista de Sistemas / Arquitetura • CI&T mar/2021 – fev/2023

- Arquitetura e desenvolvimento de microsserviços distribuídos para Open Banking, financeiro, mineração e e-commerce, com soluções escaláveis e orientadas a eventos em produção.
- Concepção da arquitetura de segurança de plataforma de análise de crédito em Open Banking: autenticação, autorização e controle de acesso com Spring Security, Ping Federate e Ping Directory.

Tecnologias: Java, Kotlin, Spring Boot, Node.js, Kafka, KSQLEDB, Kubernetes, Redis, PostgreSQL, AWS (Lambda, SQS), Azure, Docker.

Backend Developer • Hydra Systems Inc. mar/2020 – mar/2021

- Desenvolvimento e manutenção de sistemas backend de alta confiabilidade. Java, Spring Boot, PostgreSQL, MongoDB, Docker.

Analista de Desenvolvimento de Produtos • Intelbras nov/2018 – fev/2020

- Desenvolvimento de aplicativos mobile (Android e iOS) para segurança eletrônica, com CI/CD e entrega contínua. Kotlin, Swift, RxJava/RxSwift, MVVM, Firebase, Fastlane.

Arquiteto de Software / Analista de Sistemas • Grupo Nexxera 2009 – 2018

- Arquitetura e desenvolvimento de plataformas corporativas de pagamento eletrônico, cobrança e troca segura de documentos, incluindo projeto em parceria com os Correios. Java, microsserviços, REST, AngularJS, Python/Django, Oracle, AWS.

Experiência anterior em desenvolvimento corporativo desde 2003 (Gwork Consultoria e Sistemas).

PROJETOS EM IA

Development Orchestrator · open source, MIT · github.com/fabio-barboza/development-orchestrator

Framework de Spec-Driven Development que orquestra o ciclo completo de engenharia com agentes de IA autônomos: PRD, TechSpec, tasks, execução, code review e QA com testes E2E. Registry de capacidades que orienta o agente sobre qual MCP acionar em cada tipo de feature, e isolamento de contexto por subagente para filas longas de tarefas. Agnóstico de ferramenta, testado em Claude Code, Cursor, GitHub Copilot e Opencode. Instalável via `npx skills add`.

Resume Platform · RAG agêntico sobre currículos · github.com/fabio-barboza/resume-platform

Agente de triagem de currículos em Python, FastAPI, LangGraph, Postgres com pgvector e HNSW, MinIO e Langfuse. O agente decide se busca e como, entre busca semântica, busca lexical por nome e inventário. Guardrails implementados como código, não como instrução de prompt: injeção de prompt barrada de forma determinística na ingestão e critério protegido (gênero, idade, estado civil) barrado por middleware antes de qualquer recuperação. Evals automatizados de recuperação e de comportamento multi-turno. Foi o eval multi-turno que identificou uma falha de busca por nome, corrigida com ferramenta lexical dedicada. Otimização do scaffold (descrições de tools e política de busca) reduziu a latência de resposta de 54,3s para 8,2s.

Logistic Platform · agente de domínio sobre MCP em Java · github.com/fabio-barboza/logistic-platform

Agente de logística em Java 21, Spring Boot 4, Spring AI e MCP, respondendo perguntas sobre frota, rotas e entregas com resposta em texto, tabela ou gráfico. O modelo não acessa o banco: consome apenas tools MCP descobertas em runtime, e a única consulta livre roda em role Postgres somente leitura garantida por GRANT, não por validação de string. Eval automatizado de seleção de ferramentas, que pega a regressão originada no prompt e não coberta por teste convencional. Observabilidade com Langfuse.

Web Search MCP · servidor MCP autônomo de pesquisa · github.com/fabio-barboza/web_search_mcp

Servidor MCP em Python e FastMCP que pesquisa na web via SearXNG, lê as páginas e devolve um resumo com as fontes citadas. A pesquisa inteira roda em contexto isolado e devolve cerca de 700 tokens ao agente principal, no lugar dos 6k a 20k tokens do material lido, o que viabiliza conversas longas com muitas pesquisas. Proteção anti-SSRF, orçamento de contexto configurável, transportes stdio e HTTP, e avaliação automatizada da qualidade do resumo com LLM como juiz.

FORMAÇÃO

- Pós-graduação em Inteligência Artificial e Aprendizado de Máquina — PUC Minas (2024–2026)
- MBA em Arquitetura de Software — IGTI, Instituto de Gestão e Tecnologia da Informação (2018–2019)
- Sistemas para Internet — Universidade do Sul de Santa Catarina (UNISUL)

IDIOMAS

Português (nativo) · Inglês (profissional)